EPITECH. DIGITAL SCHOOL
La + Business des écoles Tech

Module de spécialisation Data Business Intelligence

20 mars 2026

Ines Krissaane

Projet 3 - Fake news

“We send the EU £350 million a week — let’s fund our NHS instead.”

— Boris Johnson

“Iraq has weapons of mass destruction.”

— George W. Bush

“Climate change is a hoax.”

— Donald Trump

Projet 3 - Fake news

Définitions

Une *fake news* (ou infox) est une information délibérément fausse ou trompeuse diffusée comme si elle était vraie, souvent avec l'intention de manipuler l'opinion, de semer la confusion ou de nuire à la confiance dans les institutions et les médias.

- Désinformation : diffusion volontaire de fausses informations pour tromper ou influencer.
- Mésinformation : partage involontaire d'erreurs ou d'imprécisions sans intention de nuire (par exemple une erreur non vérifiée).

Source : https://www.info.gouv.fr/

Projet 3 - Fake news

1. **Ce n’est pas totalement vrai**
- Information complètement fausse
- Ou partiellement vraie mais déformée

2. **Ça ressemble à une vraie information**
- Utilise des chiffres, des citations, un ton journalistique
- Imite des sources fiables

3. **Il y a une intention**
- Influencer l’opinion publique
- Manipuler politiquement
- Générer des clics ou de l’argent

Contexte

La diffusion de fake news dans le domaine politique influence les opinions publiques et les décisions.

Le projet consiste à construire un modèle de classification de déclarations politiques basé sur le **LIAR Dataset**, puis à évaluer sa capacité de généralisation sur un dataset externe.

Les étudiants apprendront à :

- traiter un dataset textuel réaliste
- construire un pipeline NLP complet
- évaluer la robustesse et le transfert de leur modèle

LIAR Dataset

Contenu :

- ~12 800 déclarations publiques de politiciens américains
- Annotées selon **6 labels de véracité** :
  - **Pants-fire** – Mensonge flagrant
  - **False** – Faux
  - **Barely-true** – À peine vrai
  - **Half-true** – Mi-vrai / mi-faux
  - **Mostly-true** – Plutôt vrai
  - **True** – Vrai
- Métadonnées disponibles **:** Auteur, parti politique, sujet, date, source

Sujets principaux : Économie / Fiscalité, Santé / Healthcare, Politique étrangère / Défense, Éducation, Environnement / Climat, Immigration, Justice

Natural Language Processing (NLP)

Le traitement automatique du langage naturel (NLP) est un sous-domaine de l'informatique et de l'intelligence artificielle (IA) qui utilise le machine learning pour permettre aux ordinateurs de comprendre et de communiquer en langage humain.

Exemples concrets :

- Détection de fake news
- Analyse des sentiments
- Chatbots et assistants vocaux
- Traduction automatique

Problème : Les modèles ML ne comprennent pas le texte brut.

TF-IDF (Term Frequency – Inverse Document Frequency)

Principe :

- TF-IDF transforme le texte en vecteurs numériques basés sur la fréquence des mots dans un document et dans l'ensemble du corpus.
- Il valorise les mots rares mais importants et diminue l'impact des mots très fréquents (comme "the", "and").

Avantages : simple, rapide, efficace pour la classification de texte.

Limites : ne capture ni le sens, ni l'ordre des mots.

$$TF(t,d) = \frac{(\text{Number of occurrences of term } t \text{ in document } d)}{(\text{Total number of terms in the document } d)}$$

$$IDF(t,D) = \log_e \frac{(\text{Total number of documents in the corpus})}{(\text{Number of documents with term } t \text{ in them})}$$

$$TF\text{-}IDF(t,d,D) = TF(t,d) \times IDF(t,D)$$

Word Embeddings : Word2Vec et GloVe

Idée principale :

- Chaque mot est représenté par un vecteur dense qui capture sa sémantique et ses relations avec les autres mots.
- Contrairement à TF-IDF, les vecteurs sont continus et plus compacts.

Word2Vec (Google, 2013)

- Apprend les vecteurs à partir du **contexte local** des mots.
- Deux architectures :
  - CBOW (Continuous Bag of Words) : prédit un mot central à partir de son contexte.
  - Skip-gram : prédit le contexte à partir du mot central.

GloVe (Stanford)

- Basé sur les **co-occurrences globales** des mots dans tout le corpus.
- Si deux mots apparaissent souvent ensemble, leurs vecteurs seront proches.

Embeddings contextuels : BERT / RoBERTa

Les embeddings contextuels représentent chaque mot **en fonction de la phrase** dans laquelle il apparaît.

Contrairement à Word2Vec / GloVe (vecteurs statiques), le même mot aura un vecteur différent selon son contexte.

Exemple : "He went to the bank to deposit money" / "She sat on the river bank to fish"

BERT (Bidirectional Encoder Representations from Transformers) - Google

- Lecture bidirectionnelle : regarde les mots avant et après pour comprendre le sens.
- Basé sur la self-attention : chaque mot “regarde” tous les autres mots dans la phrase.
- Peut être fine-tuné sur des tâches spécifiques : classification, question/réponse, etc.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.* In *Proceedings of NAACL-HLT* (pp. 4171–4186).

RoBERTa - Version améliorée de BERT - Facebook AI

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... & Stoyanov, V. (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach.* arXiv:1907.11692.

Domain shift - Points importants

1. **Longueur des textes**
   - Textes courts (LIAR) vs textes longs ou articles (FakeNewsNet, BuzzFeed)
   - Impact : difficulté à généraliser sur des phrases plus longues ou contextes étendus

2. **Style et format**
   - Déclarations directes vs style journalistique ou tweets informels
   - Impact : le modèle peut être perturbé par des formats ou ponctuations différents

3. **Vocabulaire et sujets**
   - Politique américaine vs sujets variés et expressions nouvelles
   - Impact : présence de mots inconnus ou expressions différentes → baisse de performance

4. **Ton et subtilité**
   - Déclarations directes vs ironie, sarcasme, sous-entendus
   - Impact : certains modèles (TF-IDF, Word2Vec) peuvent mal interpréter le sens

5. **Importance de l'évaluation out-of-domain**
   - Tester sur un dataset externe pour mesurer **la robustesse et la généralisation**
   - Comparer métriques (accuracy, F1-score) et analyser les erreurs

Outils d’analyse et d’interprétabilité

- SHAP ou LIME pour comprendre pourquoi le modèle se trompe sur le nouveau dataset
- Analyse des biais et considérations éthiques
  - biais liés aux sources des données
  - biais liés aux personnes citées (speakers, affiliations politiques)
  - biais introduits par les annotations humaines
  - biais linguistiques ou culturels